7

LABORATUVAR 7 · WSR 500 · Kolileme Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad _____ Grup _____ Tarih _____

> **Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: WSR 500'e YZ'li görsel ürün kontrolü (eksik veya ters dizilmiş ürün tespiti) eklenmesi planlanıyor. Proje aşaması değerlendirmesi yapıyorsunuz.

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Hatalı dizilmiş ürüne OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   YZ son karar olmamalı. Bağımsız ikinci kontrol (kural tabanlı sensör veya ağırlık kontrolü) ve örneklemeli insan onayı olmalı. Hatalı OK oranı izlenir, eşik aşılırsa hat yavaşlar veya durur.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Donmuş kare, bulanıklık, ani dağılım kayması, zaman damgası tutarsızlığı ve kamera sağlık sinyali izlenir. Görüntü sayısı ile ürün sensör sayacı çapraz kontrol edilir. Şüpheli girdide OK verilmez, fail-safe durumuna geçilir (RED veya duruş), insana sorulur ve olay kaydedilir.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik pilot veriyle ve hatanın maliyetine göre belirlenir, muhafazakâr seçilir (örneğin %90 civarı). Altında otomatik OK verilmez: önce fallback (ürün manuel kontrole ayrılır), sonra insana sorulur, düşük confidence tekrar ederse hat durdurulur.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol + insan onayı (human override, monitoring)
Girdi manipüle edildi	Şüpheli girdide RED/duruş (fail-safe) + izleme
Confidence düştü	Eşik altında insana sor veya manuel kontrol (confidence threshold, fallback)

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.